ABSTRAK

Proliferasi sistem Enterprise Resource Planning (ERP) multi-tenant telah mendemokratisasi akses terhadap layanan Machine Learning (ML) tertanam bagi Usaha Kecil dan Menengah (UKM). Platform ERP modern dilengkapi dengan modul prediktif untuk risiko keterlambatan pembayaran (late-payment), lead scoring, dan atrisi karyawan, serta semakin banyak melengkapi model-model tersebut dengan teknik post-hoc Explainable AI (XAI) seperti SHAP dan LIME. Meskipun rezim perusahaan yang kaya data terlayani dengan baik oleh kombinasi ini, ekor panjang tenant cold-start — yakni tenant yang hanya memiliki puluhan atau ratusan rekaman historis — mengungkap moda kegagalan yang sebelumnya kurang diteliti: halusinasi penjelasan (hallucinated explanations). SHAP dan LIME tetap menghasilkan atribusi yang tampak meyakinkan dan terformat rapi bahkan ketika classifier yang mendasarinya secara statistik setara dengan tebakan acak, sehingga memaparkan pengguna UKM pada rekomendasi yang tampak otoritatif namun kosong secara epistemik. Tesis ini mengkuantifikasi fenomena tersebut melalui eksperimen sparsity terkontrol pada lima tenant tersimulasi (50.000; 5.000; 1.000; 200; 50 baris) yang diambil dari korpus e-commerce Brasil Olist, yang dioperasionalisasikan sebagai tugas prediksi Late Delivery Risk (1[delivered_customer_date > estimated_delivery_date]) yang berfungsi sebagai substrat risiko operasional bergaya ERP secara struktural dan dapat digeneralisasikan ke modul late-payment pada sistem yang dikaji, serta dilatih di bawah rezim penghindaran kebocoran data (leakage) yang ketat di mana hanya observabel pada waktu pemesanan (order-time) yang diizinkan masuk ke dalam matriks fitur. Metrik prediktif klasik gagal melacak perubahan rezim tersebut: AUC-ROC tetap seragam moderat pada tingkatan kaya data, menengah, sparse, dan sangat sparse (0,6556; 0,6249; 0,6094; 0,6126) dan meningkat secara anomali menjadi 0,8889 pada tingkatan cold-start sebagai artefak sampel kecil. Kesepakatan peringkat dasar (baseline rank agreement) penjelasan SHAP terhadap tenant referensi kaya data (suatu ukuran stabilitas penjelasan yang diselaraskan dengan referensi, bukan klaim fidelitas

terhadap ground truth), yang dikuantifikasi dengan korelasi peringkat Spearman atas importansi SHAP global, menurun secara monoton dari $\rho = 1.000$ menjadi $\rho = 0.4485$, melintas di bawah ambang reliabilitas $\rho = 0.70$ pada titik 1.000 baris ($\rho_C = 0.6429$). Volatilitas penjelasan, yang diukur dengan variansi nilai SHAP absolut, melebar lebih dari dua orde besaran dari 0,0224 pada tingkatan kaya data menjadi 5,0392 pada tingkatan cold-start. Tebing kualitatif tersebut direplikasi dengan pipeline yang sama pada dua tugas ERP-native lainnya (IBM HR Analytics Employee Attrition; synthetic CRM Lead Scoring), yang mendukung validitas eksternal dari temuan arsitektural ini. Berlandaskan temuan empiris tersebut, tesis ini mengusulkan dan mengimplementasikan pola Maturity-Aware AI Routing pada ERP multi-tenant berbasis Django 4.2: sebuah gerbang logika tingkatan (tier-logic gate) (LatePaymentPredictor.predict_or_heuristic) yang menahan prediksi lokal untuk tenant di bawah ambang 1.000 faktur dan menggantikannya dengan heuristik global tingkat platform yang diturunkan dari referensi kaya data. Arsitektur yang diusulkan menyediakan kontrol tingkat sistem yang konkret dan dapat diaudit terhadap halusinasi penjelasan, serta menawarkan kepada vendor SaaS sebuah mekanisme fallback cold-start yang skalabel dan konsisten dengan regulasi akuntabilitas AI yang sedang berkembang.

Kata kunci: Explainable AI, SHAP, LIME, multi-tenant SaaS, ERP, cold-start, data sparsity, Django, reliability cliff.